

**RÉPUBLIQUE DE GUINÉE**



*Travail – Justice – Solidarité*

**MINISTÈRE DE L'ENSEIGNEMENT SUPÉRIEUR, DE LA RECHERCHE  
SCIENTIFIQUE ET DE L'INNOVATION**

.....

**UNIVERSITÉ KOFFI ANAN DE GUINÉE**



**FACULTE DES SCIENCES**

**MASTER 1 SYSTEMES D'INFORMATION**

**Cours de Fouille de Données**

---

**Projet P01 Prédiction du churn des Abonnés d'un Opérateur Mobile Guinéen**

---

**Présenté par : Mamadou Bachir Diallo**  
Matricule : MSI25006

**Enseignant : Youssouf Vessou Traoré**

**Année universitaire 2025 – 2026**

## 1. Contexte et problématique métier

TélécomGuinée SA enregistre un taux de churn de 18% par trimestre, soit 720 000 départs sur 4 millions d'abonnés. Le coût d'acquisition d'un nouveau client est estimé à 5 fois le coût de rétention. L'enjeu économique est considérable : chaque trimestre, les départs non anticipés génèrent un surcoût de plusieurs milliards de GNF en prospection.

L'objectif de ce projet est de construire un modèle de classification binaire capable d'identifier les clients susceptibles de résilier dans les 30 prochains jours, afin de déclencher automatiquement des offres personnalisées (SMS, remise forfait, appel conseiller).

## 2. Méthodologie CRISP-DM

| N° | Phase                     | Description                                                                                                         |
|----|---------------------------|---------------------------------------------------------------------------------------------------------------------|
| 1  | Compréhension métier      | Identifier les 720 000 clients à risque/trimestre. Recall cible $\geq$ 80%. ROI : coût rétention = 1/5 acquisition. |
| 2  | Compréhension des données | Analyser CDR, CRM, Orange Money, réseau OSS, NPS. Variables clés : ancienneté, réclamations, ratio data/voix.       |
| 3  | Préparation               | Nettoyage, encodage Label/One-Hot, normalisation StandardScaler, rééquilibrage SMOTE (18/82).                       |
| 4  | Modélisation              | 3 algorithmes comparés : Régression Logistique, Random Forest, XGBoost. Validation croisée k=5.                     |
| 5  | Évaluation                | Prioriser le Rappel (FN coûte 5× plus cher). AUC-ROC, F1, matrice de confusion, lift curve.                         |
| 6  | Déploiement               | Streamlit local. Score 60-75%→SMS, 75-88%→SMS+notif, >88%→appel conseiller. Réentraînement mensuel.                 |

## 3. Description du dataset

Le dataset **guinee\_telecom\_churn\_FR.csv** contient **15 000 observations** et **23 variables**. Il a été enrichi par trois variables originales (\*) créées spécifiquement pour ce projet :

| Variable               | Type  | Description                            | Rôle           |
|------------------------|-------|----------------------------------------|----------------|
| anciennete_mois *      | int   | Durée d'abonnement en mois (1-96)      | Prédicteur #1  |
| nombre_reclamations *  | int   | Total pannes + appels service client   | Prédicteur #4  |
| ratio_data_voix *      | float | donnees_mo / minutes_totales           | Profil usage   |
| pannes_signalees_30j   | int   | Pannes réseau signalées sur 30 jours   | Prédicteur #2  |
| retard_paiement_jours  | int   | Jours de retard de paiement (postpayé) | Prédicteur #3  |
| appels_service_client  | int   | Nombre d'appels au service client      | Insatisfaction |
| recharge_mensuelle_moy | int   | Recharge mensuelle moyenne en GNF      | ARPU proxy     |

| Variable    | Type | Description                        | Rôle         |
|-------------|------|------------------------------------|--------------|
| region      | str  | Région de Guinée (8 modalités)     | Géographique |
| resiliation | str  | Variable cible : Oui/Non (24% Oui) | Cible        |

Sources : données synthétiques générées avec `numpy.random`.

## 4. Préparation des données

### 4.1 Qualité initiale

Le dataset ne présente aucune valeur manquante ni doublon après enrichissement. La variable cible **resiliation** est déséquilibrée : 76% "Non" vs 24% "Oui". Ce déséquilibre modéré nécessite un traitement spécifique.

### 4.2 Encodage

- **Variables binaires** (Oui/Non, Homme/Femme, Prépayé/Postpayé) → `LabelEncoder` (0/1)
- **Variables nominales** (region, moyen\_paiement) → `One-Hot Encoding` avec `drop_first=True` pour éviter la multicollinéarité
- **Variable cible** : "Oui" → 1, "Non" → 0

### 4.3 Normalisation et rééquilibrage

Toutes les variables numériques (14 colonnes) sont normalisées avec **StandardScaler** (moyenne=0, écart-type=1). Le rééquilibrage **SMOTE** est appliqué uniquement sur l'ensemble d'entraînement, après le split train/test, pour éviter toute fuite de données (data leakage).

## 5. Modélisation

### 5.1 Protocole de validation

Split stratifié 80/20 (12 000 entraînement / 3 000 test). Validation croisée k=5 stratifiée. Seuil de décision ajusté via la courbe précision-rappel pour maximiser le F1-Score sur la classe positive (churners).

### 5.2 Tableau comparatif des modèles

| Modèle                  | Accuracy | Précision | Rappel | F1-Score | ROC-AUC |
|-------------------------|----------|-----------|--------|----------|---------|
| Régression Logistique ★ | 0.593    | 0.312     | 0.577  | 0.405    | 0.637   |
| Random Forest           | 0.667    | 0.332     | 0.385  | 0.357    | 0.630   |
| XGBoost                 | 0.675    | 0.339     | 0.374  | 0.356    | 0.630   |
| XGBoost + SMOTE         | 0.760    | 0.500     | 0.124  | 0.198    | 0.636   |

### 5.3 Justification du choix du meilleur modèle

La **Régression Logistique** obtient le meilleur F1-Score (0.405) et surtout le meilleur **Rappel** (0.577). Un faux négatif (churner non détecté) génère un surcoût de 250 000 GNF (coût d'acquisition), contre seulement 50 000 GNF pour un faux positif (offre envoyée à un client fidèle). Le ratio 1:5 justifie de prioriser le Rappel sur la Précision.

XGBoost avec SMOTE présente une Accuracy élevée (0.76) mais un Rappel très faible (0.12), signifiant qu'il manque 88% des churners réels, un résultat inacceptable d'un point de vue métier.

## 6. Variables les plus explicatives

L'analyse des coefficients de la Régression Logistique confirme les variables suivantes :

| Rang | Variable                     | Interprétation métier                                                                                                                 |
|------|------------------------------|---------------------------------------------------------------------------------------------------------------------------------------|
| 1    | <b>anciennete_mois</b> ★     | Les clients récents (< 6 mois) churne 3× plus que les clients fidèles (> 48 mois). Variable la plus prédictive dans tous les modèles. |
| 2    | <b>pannes_signalees_30j</b>  | Chaque panne signalée sur les 30 derniers jours augmente la probabilité de churn. Signal fort d'insatisfaction réseau.                |
| 3    | <b>retard_paiement_jours</b> | Les clients en retard de paiement sont plus susceptibles de résilier, signe d'une relation dégradée avec l'opérateur.                 |
| 4    | <b>nombre_reclamations</b> ★ | Combinaison de appels_service_client et pannes. Plus un client se plaint, plus il est à risque de partir.                             |
| 5    | <b>appels_service_client</b> | Proxy direct de l'insatisfaction. Un client qui appelle 4+ fois par mois est significativement plus à risque.                         |

## 7. Déploiement — Application Streamlit

Une application Streamlit (**app/app.py**) permet la prédiction en temps réel pour un client individuel. Elle comprend trois onglets :

- **Prédiction individuelle** : saisie des variables client → jauge de risque + segment + action recommandée
- **Analyse du dataset** : graphiques interactifs (churn par région, distribution ancienneté, réclamations vs churn)
- **Performance du modèle** : tableau comparatif + graphique radar + interprétation métier

Segmentation automatique des actions de rétention :

- **Score 40-60%** : Risque modéré → SMS offre data bonus (+500 Mo gratuits)
- **Score 60-80%** : Risque élevé → SMS + notification application + forfait -15%
- **Score > 80%** : Risque très élevé → Appel conseiller dans les 48h + remise VIP

## 8. Limites et pistes d'amélioration

- **Dataset synthétique** : les patterns peuvent être trop réguliers vs données réelles Orange Guinée. Une validation sur données CDR réelles est indispensable avant déploiement.
- **Features temporelles absentes** : les CDR permettraient de capturer la dynamique du comportement. Un modèle LSTM améliorerait le Rappel.
- **Données géographiques fines** : la couverture réseau par quartier (et non par région) est un facteur de churn important non capturé ici.
- **Réentraînement** : le modèle doit être réentraîné mensuellement pour éviter le drift des données.