

P01 — PRÉDICTION DU CHURN

des Abonnés d'un Opérateur Mobile Guinéen

Master 1 Fouille de Données — Université Kofi Annan de Guinée

Mamadou Bachir Diallo · Enseignant : Y. V. Traoré · Année 2025-2026

1. Contexte et problématique métier

TélécomGuinée SA (opérateur fictif inspiré d'Orange Guinée) enregistre un taux de churn de **18% par trimestre**, soit **720 000 départs** sur 4 millions d'abonnés. Le coût d'acquisition d'un nouveau client est estimé à **5 fois** le coût de rétention. L'enjeu économique est considérable : chaque trimestre, les départs non anticipés génèrent un surcoût de plusieurs milliards de GNF en prospection.

L'objectif de ce projet est de construire un modèle de classification binaire capable d'identifier les clients susceptibles de résilier dans les **30 prochains jours**, afin de déclencher automatiquement des offres personnalisées (SMS, remise forfait, appel conseiller).

2. Méthodologie CRISP-DM

1 Métier	Identifier les 720 000 clients à risque/trimestre (18%×4M). Recall cible ≥ 80%. ROI : coût rétention = 1/5 acquisition.
2 Données	Analyser CDR, CRM, Orange Money, réseau OSS, NPS. Variables clés : ancienneté, réclamations, ratio data/voix.
3 Prépa.	Nettoyage, encodage Label/One-Hot, normalisation StandardScaler, rééquilibrage SMOTE (18/82).
4 Modèles	3 algorithmes comparés : Régression Logistique (baseline), Random Forest, XGBoost. Validation croisée k=5.
5 Éval.	Prioriser le Rappel (FN coûte 5× plus cher). AUC-ROC, F1, matrice de confusion, lift curve.
6 Déploi.	Streamlit local. Score 60-75%→SMS, 75-88%→SMS+notif, >88%→appel conseiller. Réentraînement mensuel.

3. Description du dataset

Le dataset `guinee_telecom_churn_FR.csv` contient **15 000 observations** et **23 variables**. Il a été enrichi pour ce projet par trois variables originales (marquées ■) :

Variable	Type	Description	Rôle
<code>anciennete_mois</code> ■	int	Durée abonnement (1-96 mois)	Prédicteur #1
<code>nombre_reclamations</code> ■	int	Total pannes + appels SAV	Prédicteur #4
<code>ratio_data_voix</code> ■	float	<code>donnees_mo</code> / <code>minutes_totales</code>	Profil usage
<code>pannes_signalees_30j</code>	int	Pannes réseau sur 30 jours	Prédicteur #2

retard_paiement_jours	int	Jours de retard (postpayé)	Prédicteur #3
appels_service_client	int	Appels au SAV	Insatisfaction
recharge_mensuelle_moy	int	Recharge mensuelle moyenne (GNF)	ARPU proxy
region	str	Région de Guinée (8 modalités)	Géographique

Sources : données synthétiques générées avec `numpy.random`, méthode validée dans le cahier des charges du cours (cf. tableau §2 du catalogue).

4. Préparation des données

4.1 Qualité initiale

Le dataset ne présente aucune valeur manquante ni doublon après enrichissement. La variable cible **resiliation** est déséquilibrée : 76% "Non" vs 24% "Oui". Ce déséquilibre modéré nécessite un traitement spécifique (SMOTE ou pondération de classes).

4.2 Encodage

- **Variables binaires** (Oui/Non, Homme/Femme, Prépayé/Postpayé) → LabelEncoder (0/1)
- **Variables nominales** (region, moyen_paiement) → One-Hot Encoding avec drop_first=True pour éviter la multicolinéarité
- **Variable cible** : "Oui" → 1, "Non" → 0

4.3 Normalisation et rééquilibrage

Toutes les variables numériques (14 colonnes) sont normalisées avec **StandardScaler** (moyenne=0, écart-type=1). Le rééquilibrage SMOTE est appliqué *uniquement* sur l'ensemble d'entraînement, après le split train/test, pour éviter toute fuite de données (data leakage).

5. Modélisation

5.1 Protocole de validation

Split stratifié 80/20 (12 000 entraînement / 3 000 test). Validation croisée k=5 pour la sélection des hyperparamètres. Seuil de décision ajusté via la courbe précision-rappel pour maximiser le F1-Score sur la classe positive (churners).

5.2 Tableau comparatif des modèles

Modèle	Accuracy	Précision	Rappel	F1-Score	ROC-AUC
Régression Logistique ■	0.593	0.312	0.577	0.405	0.637
Random Forest	0.667	0.332	0.385	0.357	0.630
XGBoost	0.675	0.339	0.374	0.356	0.630
XGBoost + SMOTE	0.760	0.500	0.124	0.198	0.636

5.3 Justification du choix du meilleur modèle

La **Régression Logistique** obtient le meilleur F1-Score (0.405) et surtout le meilleur **Rappel** (0.577), ce qui est déterminant dans ce contexte métier. Un faux négatif (churner non détecté) génère un surcoût de **250 000 GNF** (coût d'acquisition), contre seulement **50 000 GNF** pour un faux positif (offre envoyée à un client fidèle). Le ratio 1:5 justifie de prioriser le Rappel sur la Précision.

XGBoost avec SMOTE présente une Accuracy élevée (0.76) mais un Rappel très faible (0.12), ce qui signifie qu'il manque 88% des churners réels — un résultat inacceptable d'un point de vue métier malgré ses bonnes statistiques globales.

6. Variables les plus explicatives

L'analyse des coefficients de la Régression Logistique et de l'importance des features XGBoost convergent vers les mêmes variables :

#1	anciennete_mois (■ nouvelle variable) Les clients récents (< 6 mois) churne 3× plus que les clients fidèles (> 48 mois). Variable la plus prédictive dans tous les modèles.
#2	pannes_signalees_30j Chaque panne signalée sur les 30 derniers jours augmente la probabilité de churn de ~12%. Signal fort d'insatisfaction réseau.
#3	retard_paiement_jours Les clients en retard de paiement (postpayé) sont plus susceptibles de résilier — signe d'une relation dégradée avec l'opérateur.
#4	nombre_reclamations (■ nouvelle variable) Combinaison de appels_service_client et pannes. Confirme l'hypothèse : plus un client se plaint, plus il est à risque de partir.
#5	appels_service_client Proxy direct de l'insatisfaction. Un client qui appelle 4+ fois par mois est significativement plus à risque.

7. Déploiement — Application Streamlit

Une application Streamlit (**app/app.py**) permet la prédiction en temps réel pour un client individuel. Elle comprend trois onglets :

- **Prédiction individuelle** : saisie manuelle des 19 variables client → jauge de risque + segment + action recommandée
- **Analyse du dataset** : 4 graphiques interactifs (churn par région, distribution ancienneté, répartition abonnements, réclamations vs churn)
- **Performance du modèle** : tableau comparatif + graphique radar + interprétation métier du Rappel

Segmentation automatique des actions de rétention selon le score prédit :

- **Score 40-60%** : Risque modéré → SMS offre data bonus (+500 Mo gratuits)
- **Score 60-80%** : Risque élevé → SMS + notification application + forfait -15%
- **Score > 80%** : Risque très élevé → Appel conseiller dans les 48h + remise VIP

8. Limites et pistes d'amélioration

- **Dataset synthétique** : les patterns peuvent être trop réguliers vs données réelles Orange Guinée. Une validation sur données CDR réelles est indispensable avant déploiement.
- **Features temporelles absentes** : les CDR permettraient de capturer la *dynamique* du comportement (baisse progressive de la consommation). Un modèle LSTM ou gradient boosting sur séries temporelles améliorerait le Rappel.
- **Données géographiques fines** : la couverture réseau par quartier (et non par région) est un facteur de churn important non capturé ici.

- **Réentraînement** : le modèle doit être réentraîné mensuellement pour éviter le drift des données (évolution des offres concurrentes, nouveaux comportements clients).