

RÉPUBLIQUE DE GUINÉE



Travail – Justice – Solidarité

**MINISTÈRE DE L'ENSEIGNEMENT SUPÉRIEUR, DE LA RECHERCHE
SCIENTIFIQUE ET DE L'INNOVATION**

.....

UNIVERSITÉ KOFFI ANAN DE GUINÉE



FACULTE DES SCIENCES

MASTER 1 SYSTEMES D'INFORMATION

Cours de Fouille de Données

Projet P01 Prédiction du churn des Abonnés d'un Opérateur Mobile Guinéen

Présenté par : Mamadou Bachir Diallo
Matricule : MSI25006

Enseignant : Youssouf Vessou Traoré

Année universitaire 2025 – 2026

1. Contexte et problématique métier

TélécomGuinée SA enregistre un taux de churn de 18% par trimestre, soit 720 000 départs sur 4 millions d'abonnés. Le coût d'acquisition d'un nouveau client est estimé à 5 fois le coût de rétention. L'enjeu économique est considérable : chaque trimestre, les départs non anticipés génèrent un surcoût de plusieurs milliards de GNF en prospection.

L'objectif de ce projet est de construire un modèle de classification binaire capable d'identifier les clients susceptibles de résilier dans les 30 prochains jours, afin de déclencher automatiquement des offres personnalisées (SMS, remise forfait, appel conseiller).

2. Méthodologie CRISP-DM

N°	Phase	Description
1	Compréhension métier	Identifier les 720 000 clients à risque/trimestre. Recall cible $\geq$ 80%. ROI : coût rétention = 1/5 acquisition.
2	Compréhension des données	Analyser CDR, CRM, Orange Money, réseau OSS, NPS. Variables clés : ancienneté, réclamations, ratio data/voix.
3	Préparation	Nettoyage, encodage Label/One-Hot, normalisation StandardScaler, rééquilibrage SMOTE (18/82).
4	Modélisation	3 algorithmes comparés : Régression Logistique, Random Forest, XGBoost. Validation croisée k=5.
5	Évaluation	Prioriser le Rappel (FN coûte 5× plus cher). AUC-ROC, F1, matrice de confusion, lift curve.
6	Déploiement	Streamlit local. Score 60-75%→SMS, 75-88%→SMS+notif, >88%→appel conseiller. Réentraînement mensuel.

3. Description du dataset

Le dataset **guinee_telecom_churn_FR.csv** contient **15 000 observations** et **23 variables**. Il a été enrichi par trois variables originales (*) créées spécifiquement pour ce projet :

Variable	Type	Description	Rôle
anciennete_mois *	int	Durée d'abonnement en mois (1-96)	Prédicteur #1
nombre_reclamations *	int	Total pannes + appels service client	Prédicteur #4
ratio_data_voix *	float	donnees_mo / minutes_totales	Profil usage
pannes_signalees_30j	int	Pannes réseau signalées sur 30 jours	Prédicteur #2
retard_paiement_jours	int	Jours de retard de paiement (postpayé)	Prédicteur #3
appels_service_client	int	Nombre d'appels au service client	Insatisfaction
recharge_mensuelle_moy	int	Recharge mensuelle moyenne en GNF	ARPU proxy

Variable	Type	Description	Rôle
region	str	Région de Guinée (8 modalités)	Géographique
resiliation	str	Variable cible : Oui/Non (24% Oui)	Cible

Sources : données synthétiques générées avec `numpy.random`.

4. Préparation des données

4.1 Qualité initiale

Le dataset ne présente aucune valeur manquante ni doublon après enrichissement. La variable cible **resiliation** est déséquilibrée : 76% "Non" vs 24% "Oui". Ce déséquilibre modéré nécessite un traitement spécifique.

4.2 Encodage

- **Variables binaires** (Oui/Non, Homme/Femme, Prépayé/Postpayé) → LabelEncoder (0/1)
- **Variables nominales** (region, moyen_paiement) → One-Hot Encoding avec `drop_first=True` pour éviter la multicollinéarité
- **Variable cible** : "Oui" → 1, "Non" → 0

4.3 Normalisation et rééquilibrage

Toutes les variables numériques (14 colonnes) sont normalisées avec **StandardScaler** (moyenne=0, écart-type=1). Le rééquilibrage **SMOTE** est appliqué uniquement sur l'ensemble d'entraînement, après le split train/test, pour éviter toute fuite de données (data leakage).

5. Modélisation

5.1 Protocole de validation

Split stratifié 80/20 (12 000 entraînement / 3 000 test). Validation croisée k=5 stratifiée. Seuil de décision ajusté via la courbe précision-rappel pour maximiser le F1-Score sur la classe positive (churners).

5.2 Tableau comparatif des modèles

Modèle	Accuracy	Précision	Rappel	F1-Score	ROC-AUC
Régression Logistique ★	0.593	0.312	0.577	0.405	0.637
Random Forest	0.667	0.332	0.385	0.357	0.630
XGBoost	0.675	0.339	0.374	0.356	0.630
XGBoost + SMOTE	0.760	0.500	0.124	0.198	0.636

5.3 Justification du choix du meilleur modèle

La **Régression Logistique** obtient le meilleur F1-Score (0.405) et surtout le meilleur **Rappel** (0.577). Un faux négatif (churner non détecté) génère un surcoût de 250 000 GNF (coût d'acquisition), contre seulement 50 000 GNF pour un faux positif (offre envoyée à un client fidèle). Le ratio 1:5 justifie de prioriser le Rappel sur la Précision.

XGBoost avec SMOTE présente une Accuracy élevée (0.76) mais un Rappel très faible (0.12), signifiant qu'il manque 88% des churners réels, un résultat inacceptable d'un point de vue métier.

6. Variables les plus explicatives

L'analyse des coefficients de la Régression Logistique confirme les variables suivantes :

Rang	Variable	Interprétation métier
1	anciennete_mois ★	Les clients récents (< 6 mois) churne 3× plus que les clients fidèles (> 48 mois). Variable la plus prédictive dans tous les modèles.
2	pannes_signalees_30j	Chaque panne signalée sur les 30 derniers jours augmente la probabilité de churn. Signal fort d'insatisfaction réseau.
3	retard_paiement_jours	Les clients en retard de paiement sont plus susceptibles de résilier, signe d'une relation dégradée avec l'opérateur.
4	nombre_reclamations ★	Combinaison de appels_service_client et pannes. Plus un client se plaint, plus il est à risque de partir.
5	appels_service_client	Proxy direct de l'insatisfaction. Un client qui appelle 4+ fois par mois est significativement plus à risque.

7. Déploiement Application Streamlit

Une application Streamlit (**app/app.py**) permet la prédiction en temps réel pour un client individuel. Elle comprend trois onglets :

- **Prédiction individuelle** : saisie des variables client → jauge de risque + segment + action recommandée
- **Analyse du dataset** : graphiques interactifs (churn par région, distribution ancienneté, réclamations vs churn)
- **Performance du modèle** : tableau comparatif + graphique radar + interprétation métier

Segmentation automatique des actions de rétention :

- **Score 40-60%** : Risque modéré → SMS offre data bonus (+500 Mo gratuits)
- **Score 60-80%** : Risque élevé → SMS + notification application + forfait -15%
- **Score > 80%** : Risque très élevé → Appel conseiller dans les 48h + remise VIP

Vidéo de démonstration : <https://youtu.be/7ljUc7rAUTo>

8. Limites et pistes d'amélioration

- **Dataset synthétique** : les patterns peuvent être trop réguliers vs données réelles Orange Guinée. Une validation sur données CDR réelles est indispensable avant déploiement.
- **Features temporelles absentes** : les CDR permettraient de capturer la dynamique du comportement. Un modèle LSTM améliorerait le Rappel.
- **Données géographiques fines** : la couverture réseau par quartier (et non par région) est un facteur de churn important non capturé ici.
- **Réentraînement** : le modèle doit être réentraîné mensuellement pour éviter le drift des données.